WORKSHOP 002

VALENTINA VELASCO MERA
2247648

DANIEL FELIPE ROMERO BERNAL
ETL – EXTRACCIÓN, TRANSFORMACIÓN Y CARGA

INGENIERÍA DE DATOS E INTELIGENCIA ARTIFICIAL
SANTIAGO DE CALI
2026

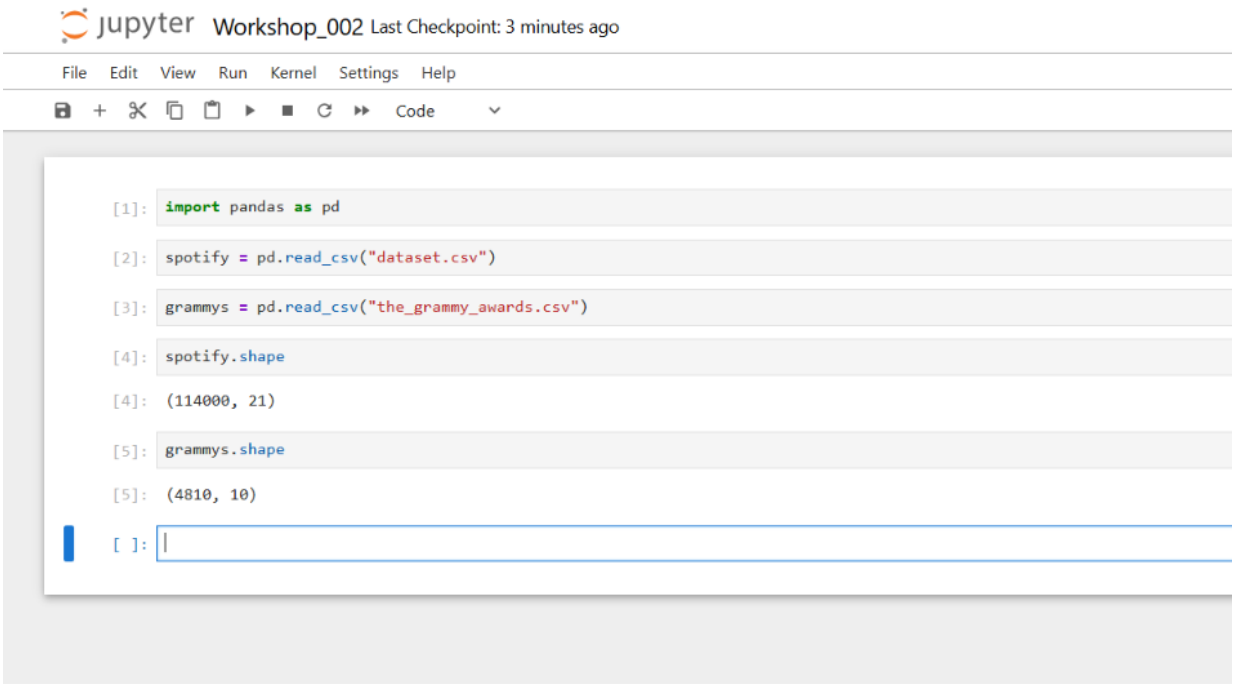
OBJETIVO

El objetivo de este trabajo es realizar un proceso ETL utilizando Python y Apache Airflow, integrando información de Spotify y de los premios Grammy. Para esto, primero se cargan y revisan los datos, luego se realiza la limpieza y transformación de la información, se integran ambas fuentes y finalmente se almacenan los resultados en una base de datos y en un archivo CSV.

EVIDENCIAS

Primero se cargaron los dos datasets en Pandas y se revisó el tamaño de cada fuente.

- Spotify: 114.000 registros y 21 columnas.
- Grammys: 4.810 registros y 10 columnas.



Evidencia 1 — Carga inicial de los datasets.

Luego se revisaron los datos para identificar si había valores faltantes. En Spotify se encontraron algunos registros sin información en artists, album_name y track_name. En Grammys también se encontraron algunos datos faltantes, principalmente en artist, workers e img, además de algunos registros que no tenían información en nominee

```
[10]: Unnamed: 0          0
      track_id            0
      artists             1
      album_name          1
      track_name          1
      popularity          0
      duration_ms         0
      explicit            0
      danceability        0
      energy              0
      key                 0
      loudness            0
      mode                0
      speechiness         0
      acousticness        0
      instrumentalness    0
      liveness            0
      valence             0
      tempo               0
      time_signature      0
      track_genre         0
      dtype: int64

[11]: grammys.isnull().sum()

[11]: year              0
      title             0
      published_at      0
      updated_at        0
      category          0
      nominee           6
      artist         1840
      workers        2190
      img            1367
      winner            0
```

Evidencia 2 — Revisión de valores nulos en Grammys.

TRANSFORMACIÓN E INTEGRACIÓN

Para poder relacionar las dos fuentes, se tomó como referencia el nombre del artista. Primero se limpiaron estos datos, eliminando espacios innecesarios y pasando los nombres a minúsculas para que fuera más fácil encontrar coincidencias. También se eliminaron los registros que no tenían un artista definido. Después se realizó la unión de las dos fuentes mediante un inner join, utilizando artist_clean como campo de relación. Finalmente se obtuvo un dataset integrado de 23.944 registros y 14 columnas:

```
[31]: merged.columns

[31]: Index(['track_id', 'artists', 'track_name', 'popularity', 'danceability',
       'energy', 'tempo', 'track_genre', 'artist_clean', 'year', 'category',
       'nominee', 'artist', 'winner'],
      dtype='str')

[32]: merged.isnull().sum()

[32]: track_id          0
      artists         1840
      track_name      1840
      popularity         0
      danceability       0
      energy             0
      tempo              0
      track_genre        0
      artist_clean    1840
      year               0
      category           0
      nominee            6
      artist          1840
      winner             0
      dtype: int64
```

Evidencia 3 — Revisión del resultado de la integración.

CARGA A LA BASE DE DATOS

Para verificar que la información se almacenó correctamente, se realizó una consulta a la base de datos después de finalizar el proceso de transformación. En esta consulta se revisó la cantidad de registros disponibles en las tablas utilizadas

```
[48]: pd.read_sql("SELECT COUNT(*) AS total FROM merged_data", con)
```

	total
0	23944

```
[49]: pd.read_sql("SELECT COUNT(*) AS total FROM grammys", con)
```

	total
0	4810

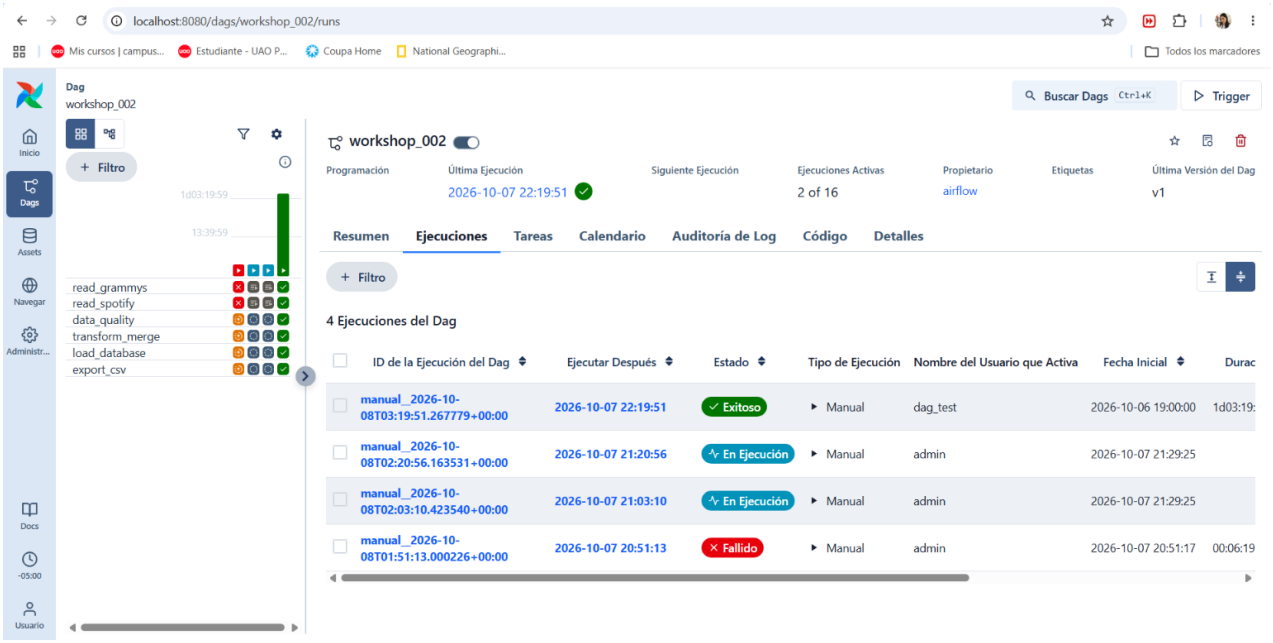
Evidencia 4 — Conteo de registros almacenados en la base de datos.

En la consulta se puede comprobar que la tabla grammys conserva los 4.810 registros originales y que la tabla merged_data contiene los 23.944 registros obtenidos después de realizar la integración. Con esto se verificó que la carga de los datos en SQLite se realizó correctamente.

AUTOMATIZACIÓN CON AIRFLOW

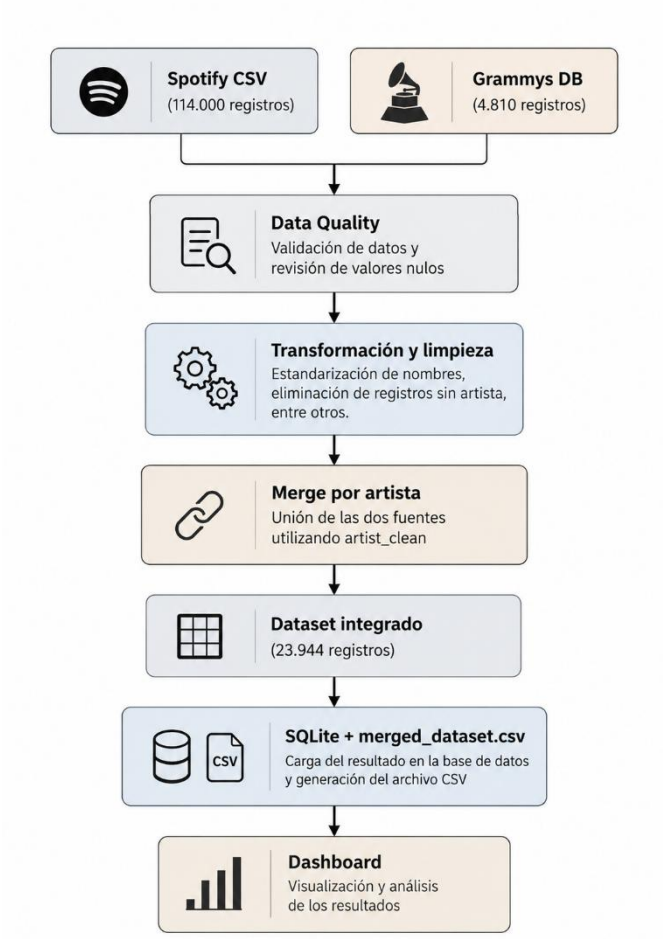
Para automatizar el proceso se creó el DAG workshop_002. El flujo está compuesto por seis tareas: read_spotify, read_grammys, data_quality, transform_merge, load_database y export_csv.

Primero se probaron las tareas de forma individual para comprobar que cada una funcionara correctamente. Después se realizó una prueba completa del DAG, en la cual todas las tareas se ejecutaron correctamente y la ejecución final terminó con estado exitoso



Evidencia 5 — Ejecución del DAG workshop_002 en Airflow.

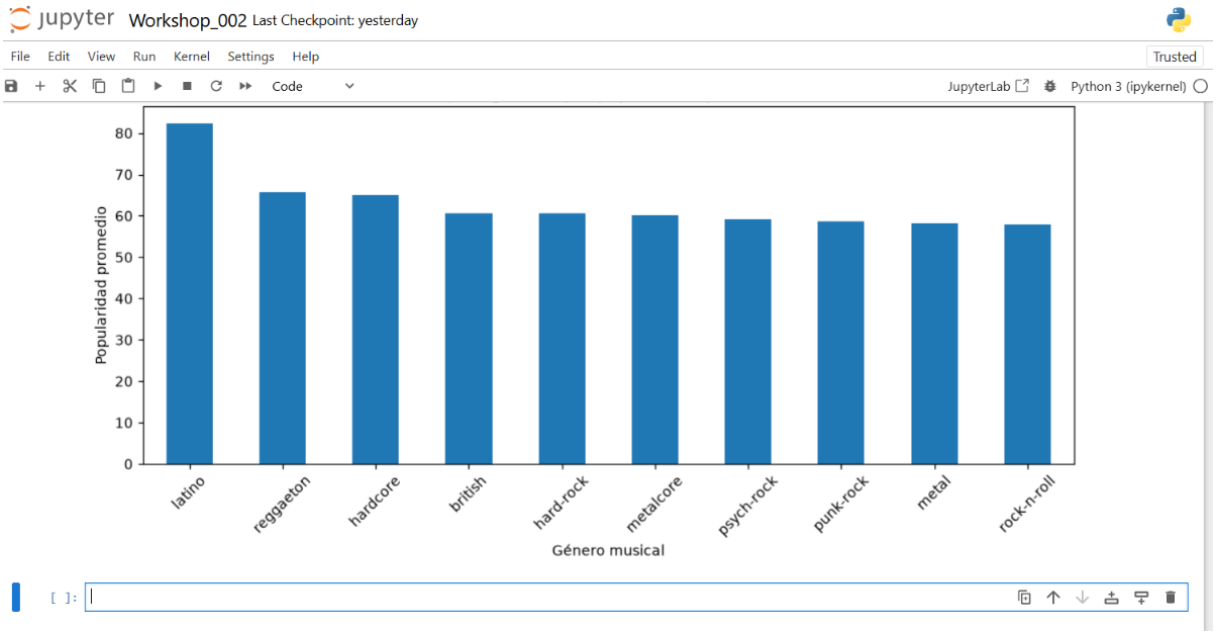
FLUJO DEL PIPELINE



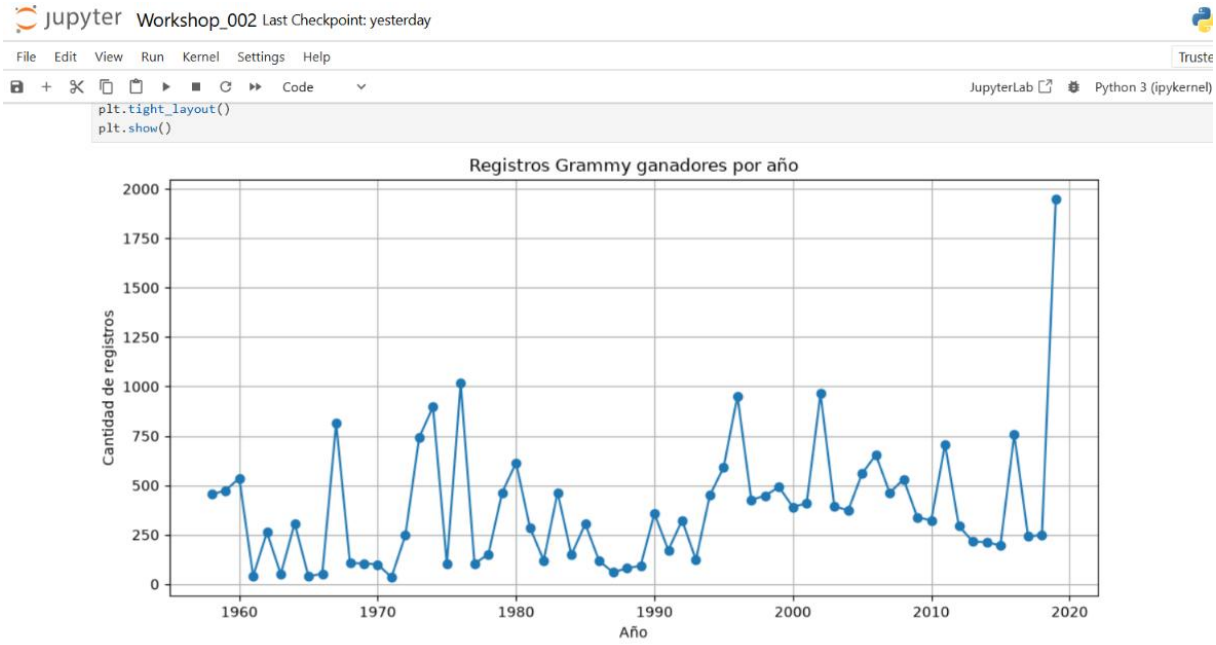
Evidencia 6 — Flujo gráfico del pipeline

DASHBOARD / REPORTE

Para el reporte se utilizó la información de la tabla merged_data de SQLite. Se cargaron los 23.944 registros desde la base de datos y se realizaron dos gráficos para revisar el comportamiento de los datos integrados.



Evidencia 6 — Top 10 géneros por popularidad promedio.



Evidencia 7 — Registros Grammy ganadores por año.

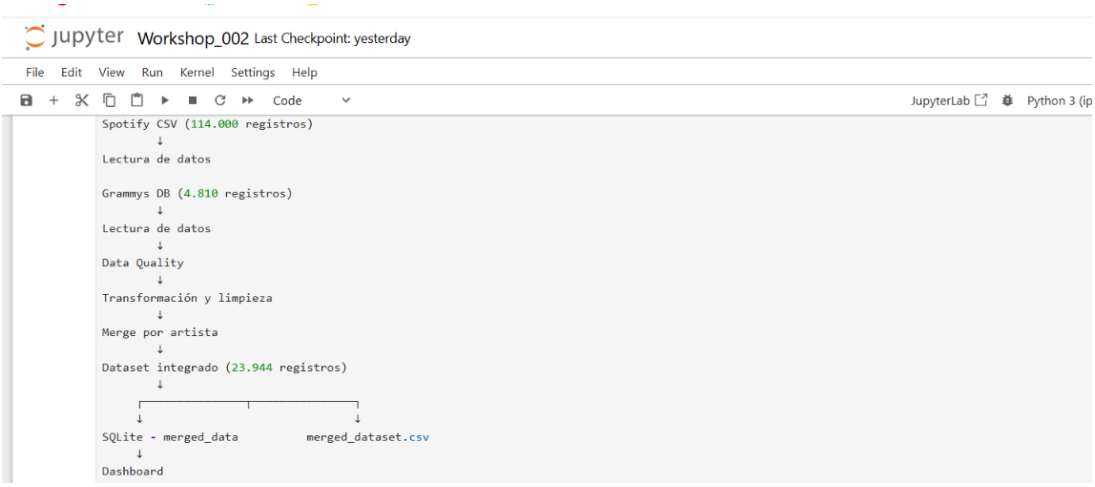
ANEXOS DE RESPALDO

Anexo 1 — Resumen del proceso

ETAPA	RESULTADO
Spotify	114.000 registros / 21 columnas
Grammys	4.810 registros / 10 columnas
Data Quality	Validación aprobada
Merge	23.944 registros / 14 columnas
SQLite	Tabla merged_data
CSV	merged_dataset.csv
Airflow	DAG workshop_002 – Exitoso

Anexo 2 — Evidencias adicionales

En esta sección se pueden agregar las capturas restantes del notebook, especialmente las relacionadas con la validación de Data Quality, el merge y la generación del archivo CSV.



Evidencia 8 — Notebook con el proceso y resultado final.

CONCLUSIÓN

Después de realizar el proceso se logró integrar la información de Spotify y Grammy mediante una limpieza y transformación de los datos. El resultado fue un dataset de 23.944 registros que quedó almacenado en SQLite y también fue exportado a CSV.

Además, el proceso se organizó en Apache Airflow y se comprobó la ejecución completa del DAG workshop_002. Finalmente, se realizó un reporte utilizando la información almacenada en la base de datos.